

Forecasting del precio de berries (WPUSI01102B): comparación de modelos con y sin Análisis Topológico de Datos (TDA)

Diana Laura Hernández Almeida Gonzalo Makenly Higuera Inzunza
José Alfredo López Torres Juan Pablo de la Peña Gonzalez
Sarah Camila Guzmán Fierro

Reto Intelica — Proyecto berry-price-tda

Junio de 2026

Resumen

Este trabajo estudia la predicción mensual del índice de precios al productor de berries en EE. UU. (serie WPUSI01102B de FRED). El objetivo central es determinar si las características derivadas del Análisis Topológico de Datos (TDA), es decir la homología persistente sobre embeddings de Takens de la serie, mejoran de forma estadísticamente significativa el desempeño de modelos de forecasting respecto a sus equivalentes sin TDA. Para ello se diseñó un experimento factorial de gran escala (cerca de 19 200 combinaciones de modelo, ventana, transformación, exógenas, estrategia de anomalías y uso de TDA), evaluado con validación cruzada temporal, y se contrastó con un conjunto de prueba fijo intacto (2022 en adelante). Los resultados muestran que el efecto del TDA es estadísticamente detectable pero de magnitud insignificante (δ de Cliff = 0.047) y, de hecho, ligeramente desfavorable en MAE; el mejor modelo final es un Ridge sin TDA ni exógenas (MAE = 29.79). Se concluye que, para esta serie, la topología no aporta señal predictiva útil más allá de la ya contenida en los retardos.

1 Introducción

1.1 Descripción del problema

Los precios de las berries (fresas, arándanos, frambuesas) son notoriamente volátiles: combinan una marcada estacionalidad anual (ligada a ciclos de cosecha), tendencias de mediano plazo (inflación, costos de insumos) y choques abruptos (clima, logística). Predecir su evolución es relevante para productores, comercializadores y planeación de inventarios. Trabajamos sobre el Producer Price Index de berries de la Bureau of Labor Statistics de EE. UU., publicado por FRED bajo el identificador WPUSI01102B, una serie mensual con fuerte componente estacional y no estacionaria en nivel.

1.2 Objetivo

El objetivo del estudio es comparar modelos de forecasting con y sin TDA para el horizonte $t+1$ (y proyecciones a futuro), respondiendo de forma cuantitativa y con pruebas de hipótesis a tres preguntas:

1. ¿El uso de características topológicas (TDA) mejora la precisión de forma estadísticamente significativa?
2. ¿El uso de variables exógenas la mejora?
3. ¿Qué factores del pipeline (modelo, ventana, transformación) influyen más en el error?

1.3 Datos

La serie objetivo WPUSI01102B se descarga directamente de FRED (script `download_berry_data.py`) y abarca 215 observaciones mensuales desde junio de 2008 hasta abril de 2026. El índice varía entre 69.2 y 299.4, con media cercana a 142.5.

Adicionalmente se construyó un conjunto de variables exógenas (script `download_exogenous.py`), alineadas a frecuencia mensual:

- `cpi_fresh_fruits`: CPI de frutas frescas (FRED CUSR0000SAF113), presión de demanda.
- `ppi_fertilizers`: PPI de fertilizantes (FRED WPU0652), costo de insumos.
- `diesel_price`: precio del diésel USD/galón (FRED APU000074714), costo logístico.
- `mxn_usd`: tipo de cambio FIX MXN/USD (Banxico SF43718), relevante por el origen de importaciones.

Las series se consolidan en `data/interim/berry_features.csv`, con imputación conservadora (forward y backward fill) de huecos puntuales. La Figura 1 muestra la serie completa.



Figura 1: Serie histórica del índice WPUSI01102B (2008 a 2026), con su marcada estacionalidad anual, tendencia creciente y choques de precio.

2 Metodología

2.1 Análisis Topológico de Datos (TDA) en series de tiempo

El TDA cuantifica la forma de los datos. Para una serie temporal 1D se aplica el siguiente pipeline por ventana (módulo `features/tda.py`):

1. Embedding de Takens: cada ventana 1D se transforma en una nube de puntos en $\mathbb{R}^d$ mediante retardos (dimensión de embedding = 6, time delay configurable). Si la serie tiene dinámica periódica, esta nube traza un lazo.
2. Homología persistente (Vietoris–Rips) sobre la nube, que detecta componentes conexas (H_0) y ciclos o lazos (H_1) a múltiples escalas.
3. Diagrama de persistencia (birth, death) de los rasgos topológicos.
4. Vectorización en 8 características por ventana: `max_pers_h1`, `mean_pers_h1`, `std_pers_h1`, `n_cycles_h1`, `entropy_h1` (entropía de persistencia), `amplitude_h1` (norma L_2), `max_pers_h0` y `n_comp_h0`.

La intuición es que la persistencia de los ciclos H_1 codifica la fuerza de la estacionalidad de cada ventana de forma invariante a traslaciones y deformaciones suaves. Las matrices TDA se sanan (eliminación de columnas constantes y recorte de valores extremos a $\pm 5\sigma$ con estadísticos del entrenamiento) para no desestabilizar a los modelos lineales.

2.2 Pipeline con y sin TDA

El problema se plantea como regresión supervisada a un paso (`features/builder.py`): mediante ventanas deslizantes de tamaño w se construye X y se predice el valor en $t+1$. La matriz de diseño ensambla bloques de forma factorial:

- Retardos del objetivo (la ventana), siempre presentes.
- Exógenas (valor actual con retardos opcionales), de manera opcional.
- Características TDA de la ventana, opcional, que es el factor en estudio.

Para combatir la no estacionariedad el objetivo se modela en transformación (`none`, `standard`, `diff`, `log_diff`, `seasonal_diff`); el nivel se reconstruye después sumando la diferencia predicha a la base. Las anomalías se tratan con una de cinco estrategias (`none`, `dummy`, `winsorize`, `exclude`, `isolation`). Así, las variantes con TDA y sin TDA comparten exactamente el resto del pipeline, lo que aísla el efecto de la topología.

2.3 Modelos comparados

Se evaluaron dos familias, cada una en su variante sin TDA y con TDA:

- Regresores supervisados (`models/sklearn_models.py`): `LinearRegression`, `Ridge`, `Lasso`, `ElasticNet`, `KNN`, `SVR_rbf`, `DecisionTree` y `GradientBoosting`, sobre la matriz de ventanas (estos absorben el rol de un `Random Forest` o `boosting`).
- Modelos clásicos univariados (`models/classical.py`): `SARIMA(1, 1, 1)(1, 1, 1)12`, `Exponential Smoothing` (`Holt-Winters`), `Theta` y `Seasonal Naive`.
- Redes neuronales (`models/keras_models.py`): cinco arquitecturas para el horizonte $t+1$ (`MLP`, `LSTM`, `GRU`, `CNN1D` y una híbrida `CNN_LSTM`), con escalado `z-score`, `dropout` y `early stopping` sobre una fracción de validación temporal.

Las redes neuronales se incluyeron y evaluaron, pero su mayor complejidad y número de parámetros, frente al tamaño reducido de la muestra (215 observaciones mensuales), produjeron sobreajuste de forma sistemática: ajustaban muy bien el entrenamiento pero generalizaban peor que los modelos lineales y `SARIMA` en validación y prueba. Por ello no se reportan entre las configuraciones ganadoras y el análisis se centra en los modelos más parsimoniosos. Como comparación dirigida adicional al estilo del enunciado se incluyó un contraste `RF Sin TDA`, `RF + TDA`, `SARIMA` y `SARIMA + TDA` (Sección 3.3).

2.4 Validación

Se usó una partición temporal en tres bloques (`data/loader.py`):

- Entrenamiento: hasta diciembre de 2019.
- Validación: enero 2020 a diciembre 2021 (para la optimización con `Optuna`).
- Prueba: enero 2022 en adelante, intacto, reservado para la evaluación final honesta.

La inferencia estadística (la pregunta de si ayuda el TDA) se realiza sobre los folds de un `TimeSeriesSplit` aplicado a entrenamiento más validación, registrando las métricas por fold para habilitar pruebas pareadas (mismo setup con y sin cada factor, en el mismo fold). El espacio factorial completo asciende a cerca de 19 200 combinaciones (`pipelines/experiment.py`). Las métricas reportadas son `MAE`, `RMSE`, `MAPE (%)` y R^2 .

3 Resultados

3.1 Desempeño en validación cruzada y efecto del TDA

El análisis factorial sobre los folds permite cuantificar el efecto marginal de cada factor. La regresión sobre el `MAE` (Tabla 2) y las pruebas pareadas de `Wilcoxon` (Tabla 1) coinciden:


Tabla 1: Pruebas pareadas (Wilcoxon) del efecto de cada factor sobre el MAE. Un signo positivo en la diferencia media indica que activar el factor aumenta el error. δ es el tamaño de efecto de Cliff.

Factor	n pares	MAE on	MAE off	dif. media	p -valor	efecto (δ)
use_tda	43 520	33.35	32.59	+0.76	$< 10^{-300}$	insignif. (0.047)
has_exog	5 440	33.13	30.64	+2.49	2.9×10^{-144}	insignif. (0.081)


Aunque ambos efectos son significativos por el enorme n , el tamaño de efecto es insignificante y el signo es adverso: tanto el TDA (+0.76 MAE) como las exógenas (+2.49 MAE) tienden a empeorar ligeramente el error promedio en validación cruzada. La regresión factorial lo confirma: el coeficiente de use_tda es +0.763 ($p = 8.7 \times 10^{-4}$) y el de has_exog es +2.489 ($p = 1.4 \times 10^{-7}$).

Tabla 2: Coeficientes seleccionados de la regresión del MAE sobre los factores del pipeline (referencia: DecisionTree, $w = 12$, transformación diff). Un coeficiente mayor que cero implica mayor error.

Factor	coef.	p -valor	signif.
Intercepto	27.02	0.0	sí
modelo[KNN]	-7.43	5×10^{-59}	sí
modelo[SVR_rbf]	-7.22	6×10^{-56}	sí
modelo[GradientBoosting]	-5.85	3×10^{-37}	sí
modelo[ElasticNet]	-5.58	5×10^{-34}	sí
modelo[LinearRegression]	+16.45	≈ 0	sí
window[48]	+11.41	≈ 0	sí
transform[seasonal_diff]	+7.01	5×10^{-79}	sí
transform[log_diff]	-1.20	8×10^{-4}	sí
use_tda	+0.76	9×10^{-4}	sí
has_exog	+2.49	1×10^{-7}	sí



(a) Efecto del TDA.



(b) Efecto de las exógenas.

Figura 2: Distribución del MAE por fold con y sin cada factor. En ambos casos las distribuciones se solapan casi por completo.




Figura 3: Influencia de cada factor del pipeline sobre el MAE: el modelo y la longitud de ventana dominan; el TDA es marginal.

3.2 Desempeño final en el conjunto de prueba (2022 en adelante)

Los modelos ganadores (seleccionados sin tocar el conjunto de prueba) se evaluaron sobre el periodo de prueba. La Tabla 3 y la Figura 4 resumen el resultado: el mejor modelo es un Ridge sin exógenas ni TDA (ventana 12, transformación log_diff), con $MAE = 29.79$ y $R^2 = 0.469$. La variante con exógenas (un Lasso) queda prácticamente empatada, y ninguna de las configuraciones ganadoras emplea TDA.

Tabla 3: Métricas en el conjunto de prueba (enero 2022 en adelante) de las configuraciones finales.

Modelo	MAE	RMSE	MAPE (%)	R^2
Mejor sin exógenas (Ridge, log_diff)	29.79	37.09	21.52	0.469
Mejor con exógenas (Lasso, ppi_fertilizers)	30.00	37.79	21.79	0.449
Mejor estadístico en validación cruzada	31.94	41.03	21.78	0.350




Figura 4: Comparación de predicciones contra los valores reales en el conjunto de prueba 2022 en adelante para los tres modelos finales.




Figura 5: Ranking y métricas de las configuraciones evaluadas en el conjunto de prueba.

3.3 Comparación dirigida RF y SARIMA con y sin TDA

Replicando el contraste sugerido en el enunciado sobre la ventana reciente (Tabla 4), se observa el mismo patrón: SARIMA domina ampliamente a los modelos basados en Random Forest, y añadir TDA prácticamente no cambia el resultado (mejora marginal de +0.25% en RF y un leve deterioro en SARIMA).

Tabla 4: Comparación dirigida sobre la ventana reciente (2025 a 2026). La columna de mejora se mide respecto al RF base.

Modelo	MAE	RMSE	R^2	Mejora vs. RF base
RF Sin TDA	41.19	52.10	-0.131	(base)
RF + TDA	41.09	52.04	-0.128	+0.25%
SARIMA	29.42	36.11	0.457	+28.58%
SARIMA + TDA	30.60	36.45	0.446	+25.71%

3.4 Predicciones futuras

La Tabla 5 presenta el pronóstico directo a 12 meses (mayo 2026 a abril 2027) de los cuatro modelos. Todos capturan el repunte estacional de otoño, aunque RF y SARIMA discrepan en la magnitud del pico (por ejemplo, octubre 2026). Una vez más, las variantes con y sin TDA son casi indistinguibles.


Tabla 5: Pronóstico del índice WPUSI01102B a 12 meses.

Mes	RF Sin TDA	RF + TDA	SARIMA	SARIMA + TDA
May 2026	111.10	109.85	124.98	125.47
Jun 2026	114.72	113.77	116.08	116.38
Jul 2026	110.50	110.71	114.16	114.47
Ago 2026	113.12	112.90	116.60	116.93
Sep 2026	125.79	125.98	129.43	130.06
Oct 2026	218.96	220.61	139.75	140.19
Nov 2026	177.47	177.19	208.96	207.59
Dic 2026	164.59	164.02	218.88	217.77
Ene 2027	154.82	151.40	192.14	191.31
Feb 2027	158.91	157.91	186.08	185.75
Mar 2027	134.59	133.92	135.98	136.09
Abr 2027	111.40	112.51	148.75	149.36

3.5 Optimización de hiperparámetros (Optuna)

El barrido factorial completo de la Sección anterior recorre cerca de 19 200 combinaciones por fold y, aunque es ideal para inferencia estadística (permite medir el efecto marginal de cada factor con pruebas pareadas), tiene un costo computacional alto y crece de forma multiplicativa con cada nuevo factor o nivel. Por ello se incorporó además una búsqueda con Optuna sobre el conjunto de validación, que aproxima la mejor configuración mediante muestreo bayesiano sin evaluar exhaustivamente toda la malla.

Esto justifica su uso en dos escenarios prácticos: cuando se disponga de más datos o más factores (donde el barrido marginal completo se vuelve inviable por el tiempo de cómputo) y cuando no se quiera o no se pueda costear un entrenamiento tan largo. Optuna alcanza configuraciones competitivas en una fracción de las evaluaciones, lo que lo hace adecuado para un entorno industrial donde el modelo debe re-entrenarse con frecuencia y bajo restricciones de tiempo. La Figura 6 muestra la convergencia y la importancia de hiperparámetros de esta búsqueda.

**Figura 6:** Optimización con Optuna de la configuración del pipeline.

4 Discusión

La evidencia es consistente a lo largo de las tres líneas de análisis (factorial en validación cruzada, evaluación en prueba y comparación dirigida RF y SARIMA) y apunta en la misma dirección: para esta serie el TDA no aporta señal predictiva útil. Aunque las pruebas detectan un efecto significativo (consecuencia del tamaño muestral de decenas de miles de pares), el tamaño de efecto de Cliff (0.047) es despreciable y el signo es contraproducente.

Una explicación plausible es que la estacionalidad de la serie, el rasgo que la homología persistente H_1 pretende capturar, ya está plenamente codificada en los retardos de la ventana, que todos los modelos reciben. El TDA, por tanto, agrega redundancia y dimensionalidad (8 columnas extra) sin información nueva, lo que perjudica especialmente a los modelos lineales regularizados. El resultado para las exógenas es análogo: añaden ruido más que señal en el horizonte $t+1$.

Hallazgos secundarios: el modelo y la longitud de ventana son los factores dominantes, donde ventanas largas ($w = 48$) degradan mucho el error (+11.4 MAE); la transformación `log_diff` es la mejor y `seasonal_diff` la peor; y SARIMA es un baseline muy competitivo, difícil de superar por los regresores supervisados.

5 Conclusiones

Resumen de hallazgos

- El mejor modelo final es Ridge sin TDA ni exógenas ($\text{MAE} = 29.79$, $R^2 = 0.469$ en prueba).
- El efecto del TDA es estadísticamente detectable pero de magnitud insignificante ($\delta = 0.047$) y ligeramente adverso (+0.76 MAE).
- Las exógenas tampoco ayudan en $t+1$ (+2.49 MAE).
- SARIMA supera a los modelos tipo RF por un amplio margen (cerca de 29%).

Conclusiones

Para el forecasting del precio de berries (WPUSI01102B), no se justifica el uso de TDA: el costo computacional adicional de la homología persistente no se traduce en mejor precisión, porque la información topológica ya está implícita en los retardos. Un modelo lineal regularizado sencillo sobre la serie diferenciada en logaritmos, o bien un SARIMA estacional, ofrecen el mejor compromiso entre precisión y simplicidad.

Trabajo futuro

- Evaluar TDA en horizontes más largos ($h > 1$) o en clasificación de regímenes y anomalías, donde la forma global podría ser más informativa que para regresión a un paso.
- Explorar otras vectorizaciones topológicas (persistence images, landscapes) y embeddings multivariados que incorporen exógenas.
- Probar modelos secuenciales (LSTM o Temporal CNN) y combinaciones de SARIMA con regresores.
- Ampliar el conjunto exógeno (clima, índices de producción agrícola) con retardos seleccionados por causalidad.

Reproducibilidad. Repositorio: <https://github.com/xGonks/berry-price-tda>. Código en `src/berry_price_tda/` y `scripts/`. Todo el flujo se orquesta con un Makefile: `make data` y `make exog` descargan la serie y las exógenas, `make optuna` y `make optuna-exog` ejecutan la búsqueda de hiperparámetros, `make experiment` corre el barrido factorial completo con su análisis estadístico, y `make full` encadena el proceso de principio a fin (datos, exógenas, Optuna, factorial, análisis). Resultados en `data/processed/` y figuras en `reports/figures/`.